

Rapport - California Housing

1) Mål & valt spår

- Vad vill “kunden/företaget” kunna göra?

Kunden vill bygga ett verktyg som kan användas när ett **nytt område** (eller ett område som inte är analyserat ännu) dyker upp. De har tillgång till områdets egenskaper (geografi, hushåll, inkomstnivåer osv.) men **de vet inte bostadsvärdet än**. För att prioritera var man ska lägga tid och resurser vill de kunna få en snabb klassning: *”ser detta ut som ett högpris-område?”*

- Vilket spår valde du och varför?

Jag valde spår B för att det kändes roligare med att kunna klassificera ett högt prisområde, med verkliga features och att kunna se vad kan det påverkas av.

2) Kort data-insikt (EDA)

- 2–3 observationer du gjorde om datan (med stöd av någon figur/tabell)

Den explorativa dataanalysen visar att datasetet är obalanserat, där cirka 20 % av observationerna klassas som högprisområden. Vidare indikerar korrelationsanalysen att median_income har en relativt stark positiv relation till bostadsvärden. Slutligen visar variationen i de geografiska variablerna latitude och longitude att geografiskt läge kan spela en viktig roll för bostadsmarknaden.

3) Metod (ML-flöde)

- Beskriv kort varför vi har ett testset och hur du använder det.

Vi har ett testset för att kunna verifiera min modell på ett verkligt och ärligt sätt. Den används som ett prov i slutet, efter man är klar med att träna modellen.

- Hur du delade data (train/test) och hur du utvärderade
- Vilken metric du utvärderade/optimerade mot och varför

Datan delades upp i ett träningsset och ett testset med hjälp av train_test_split. En stratify split används för att säkerställa att fördelningen av high?_value var ungefär detsamma på 20%. Träningsdatan användes för att träna och jämföra modeller samt hyperparametertuning. Cross validation genomfördes med flera folds för att mer stabil uppskattning av modellernas prestanda. Den slutliga modellen utvärderades sedan på testdatan. Modellens prestanda

utvärderades med F1- score eftersom datasetet var obalanserat och F1 balanserar både precision och recall. Resultatet analyserades även med hjälp av en **confusion matrix** för att förstå vilka typer av fel modellen gör. Vilka modeller du testade och varför (kort)

4) Resultat

- Jämförelse av modeller (kort)

Flera modeller testades för att förutsäga high_value, inklusive Logistic Regression, Decision Tree och Random Forest, samt en Dummy-baseline för jämförelse. Modellerna jämfördes med hjälp av cross-validation och F1-score, eftersom datasetet är obalanserat. Random Forest uppnådde den bästa genomsnittliga prestandan och valdes därför för vidare optimering.

- Resultat efter tuning av vald modell

Den valda modellen (Random Forest) optimerades med hjälp av GridSearchCV, där flera hyperparametrar testades, inklusive antal träd (n_estimators), maximal djup (max_depth), samt parametrar för hur träden delas (min_samples_split och min_samples_leaf). Efter hyperparameteroptimeringen förbättrades modellens F1-score jämfört med standardinställningarna, vilket indikerar att tuning bidrog till bättre modellprestanda.

- Slutlig test-prestanda

Den optimerade modellen utvärderades slutligen på testdatan, som inte användes under träningen. Modellen uppnådde ett F1-score på cirka 0.76 för klassen high_value, med en precision på cirka 0.85 och en recall på cirka 0.69. Detta innebär att modellen relativt ofta identifierar högprisområden korrekt, men missar vissa områden. Sammantaget visar resultaten att modellen har en rimlig balans mellan precision och recall och kan användas för att prioritera områden för vidare analys.

5) Rekommendation

- Vilken modell du rekommenderar och varför (koppla till metric + syfte)

Jag rekommenderar Random Forest som slutlig modell. Modellen valdes efter jämförelse av flera modeller med hjälp av cross-validation, där Random Forest hade högst värde på Mean F1 – Std F1, vilket indikerar både god prestanda och relativt stabila resultat. F1-score användes som huvudmetric eftersom datasetet är obalanserat och vi vill balansera precision och recall när vi identifierar högprisområden (high_value). Efter hyperparameteroptimering uppnådde Random Forest ett F1-score på cirka 0.76 på testdatan, vilket visar att modellen kan identifiera högprisområden relativt väl samtidigt som antalet falska positiva hålls på en rimlig nivå. Detta gör modellen lämplig för syftet att prioritera områden som sannolikt är högprisområden, vilket kan hjälpa teamet att fokusera sina resurser på mer lovande områden.

6) Risker & begränsningar

- Vad kan gå fel i verkligheten? (till exempel datakvalitet, generalisering, leakage, tolkning)

Det finns flera faktorer som kan påverka modellens tillförlitlighet i verkliga situationer. För det första kan datakvaliteten påverka resultaten. Om datan innehåller fel, saknade värden eller inte är representativ för nya områden kan modellens prediktioner bli mindre tillförlitliga. En annan risk är generaliseringsförmågan. Modellen är tränad på historisk data och kanske inte fungerar lika bra på framtida områden där marknadsförhållanden eller socioekonomiska faktorer har förändrats. Det finns också risk för felaktig tolkning av modellen. Även om modellen kan identifiera områden som sannolikt är högprisområden betyder det inte att den ger en exakt bild av bostadsmarknaden. Resultaten bör därför användas som ett beslutsstöd, inte som ett definitivt beslut. Slutligen kan det finnas risk för data leakage eller beroenden mellan variabler, även om försiktighet har tagits för att endast använda X-variabler vid modellträning och hålla testdata separerad från träningsprocessen.

7) Öövervakad inlärning

Redogör kort för:

- vad oövervakad inlärning är

Det är en maskininlärning utan målvariabel. Detta görs för att försöka identifiera grupper, mönster eller strukturer i datan.

- när det är relevant i det här caset

I detta case är det relevant eftersom den möjliggör identifiering av naturliga grupper av områden baserat på deras egenskaper. Detta kan användas för att segmentera marknaden, få en bättre överblick över datan samt identifiera olika typer av områden som kan prioriteras på olika sätt

- vad PCA respektive klustring är till för

PCA handlar om att förenkla datan genom att minska antal variabler utan att förlora mycket. Klustring är för gruppering av datapunkter som är lika varandra.

- två risker/fallgropar

Klustring kan skapa grupper som inte nödvändigtvis är meningsfulla i verkligheten, utan snarare speglar matematiska likheter i datan. Dessutom är resultaten känsliga för val av parametrar och preprocessing, vilket innebär att olika inställningar kan ge olika kluster.

- För **VG**: redogörelse + din implementation (PCA eller KMeans) och kort tolkning.

Klustringsanalysen visar att datan kan delas in i tre grupper. Klustren verkar främst skilja sig geografiskt, där vissa grupper dominerar i norra respektive södra delar av Kalifornien.

Skillnaderna i andelen högrprisområden mellan klustren är relativt små, vilket tyder på att klustringen främst fångar geografisk struktur snarare än prisnivåer. Resultaten kan användas för att segmentera områden, men bör tolkas med viss försiktighet.

8) Självreflektion

- Vad gjorde du bra? Vad var svårast?

En styrka i arbetet var valet av metric och modell i relation till problemet. Eftersom datasetet är obalanserat valdes F1-score, vilket gav en mer rättvis utvärdering av modellens prestanda. Även EDA-delen bidrog till en bättre förståelse av datan och hjälpte till att identifiera relevanta variabler. Den största utmaningen var den oövervakade delen, särskilt att tolka resultaten från klustringen på ett meningsfullt sätt och koppla dem till verkliga användningsområden. Det var inte helt tydligt hur klustren kunde användas praktiskt, vilket visar att oövervakad inlärning kan vara svårare att tolka än övervakade modeller.

- Vilket betyg (G eller VG) tycker du din inlämning motsvarar? – Motivera genom att hänvisa till konkreta krav (G/VG) i kursplanen du uppfyllt

Jag bedömer att min inlämning motsvarar **VG**. För G-nivå har jag uppfyllt samtliga grundkrav, inklusive dataförståelse (EDA), korrekt train/test-split med stratifiering, implementering av flera modeller samt utvärdering med lämplig metric. För VG-nivå har jag även genomfört en mer fördjupad analys genom att jämföra modeller med cross-validation, optimera en vald modell med hyperparameter-tuning samt motivera modellvalet utifrån både metric och problemets syfte. Dessutom har jag implementerat oövervakad inlärning med KMeans, där jag systematiskt valde antal kluster med hjälp av både elbow-metoden och silhouette score. Jag har även analyserat och tolkat klustren samt diskuterat hur resultaten kan användas som beslutsstöd. Sammantaget anser jag att arbetet visar både teknisk korrekthet och förmåga att tolka och resonera kring resultaten, vilket motsvarar kriterierna för VG.